

UNIVERSIDAD PERUANA CAYETANO HEREDIA
FACULTAD DE CIENCIAS E INGENIERÍA
“ALBERTO CAZORLA TALLER”



TEMA:

Sistema de Recomendación de Películas

CURSO:

Métodos Numéricos y Optimización para Machine Learning

ALUMNOS:

ANDRES STEVEN RODAS JANAMPA
MARCELO JOEL RODRIGUEZ CABRERA
PATRICIA DEL PILAR REBATTI JERI

PROFESORES:

JOSUE ANGEL MAURICIO SALAZAR
JEREMY KARSEN HOLGUIN MORI

Lima - Perú

2025

Abstract

El fenómeno de la sobreabundancia de información en las plataformas de streaming modernas genera fatiga de decisión en los usuarios, requiriendo sistemas eficientes de filtrado de contenido. El presente proyecto, denominado MOVIE_ML, desarrolla un ecosistema híbrido de recomendación basado en el dataset TMDb para mitigar este problema mediante técnicas de álgebra lineal y optimización numérica. La metodología se estructura en un flujo de procesamiento de datos riguroso que aborda el problema de la dispersión matricial (sparsity) mediante la normalización heterogénea de metadatos. Se implementa un motor de filtrado basado en contenido, el cual consolida atributos cualitativos en un espacio semántico (Tag Soup) y emplea vectorización TF-IDF con normalización L2 para calcular la Similitud del Coseno, resolviendo eficazmente el problema de arranque en frío (cold start). Adicionalmente, para capturar patrones de comportamiento latentes, se diseña un entorno de simulación poblacional con usuarios sintéticos, sobre el cual se ejecuta una arquitectura de optimización mediante Factorización de Matrices y Descenso de Gradiente Estocástico (SGD). La evaluación sistémica del modelo se alinea con estándares industriales (Precisión@K y RMSE), demostrando cómo la intersección entre ingeniería de características y métodos probabilísticos permite construir una herramienta altamente escalable que transforma el gusto cinematográfico en una variable estrictamente cuantificable y geométricamente optimizable.

INTRODUCCIÓN

En la era de la economía digital, las plataformas de streaming enfrentan el fenómeno de la sobreabundancia de información, donde la inmensidad de los catálogos genera en el usuario una fatiga de decisión que degrada la experiencia de consumo. Ante esta necesidad de filtrar contenido de manera eficiente, nace el proyecto MOVIE_ML: un proyecto de recomendación construido sobre el dataset de TMDb que transforma la búsqueda de contenido en una experiencia de descubrimiento geoméricamente optimizada.

El núcleo del sistema reside en la aplicación de álgebra lineal y métodos numéricos de alto rendimiento. Mediante la vectorización de metadatos cualitativos (reparto, géneros y dirección) en espacios multidimensionales, el sistema emplea el cálculo de la similitud del coseno para determinar la proximidad geométrica entre contenidos, tratando el gusto cinematográfico como una variable cuantificable.

No obstante, el rigor del proyecto trasciende la comparación de atributos al implementar una arquitectura de Factorización de Matrices optimizada mediante el Descenso de Gradiente Estocástico (SGD). Debido a la ausencia de interacciones reales en el conjunto de datos original, se desarrolló un entorno controlado de usuarios sintéticos y calificaciones simuladas bajo distribuciones normales, permitiendo al algoritmo minimizar iterativamente la función de pérdida y capturar factores latentes de preferencia. A través de este enfoque híbrido, el proyecto demuestra cómo la intersección entre la subjetividad humana y la precisión algorítmica permite construir una herramienta que se ajusta matemáticamente a la identidad de cada usuario.

Estado del Arte

El desarrollo e implementación de sistemas de recomendación cinematográficos modernos se fundamenta en la evolución de arquitecturas algorítmicas probadas en entornos de producción a gran escala, tales como los motores de recomendación históricos de Netflix y plataformas de distribución digital. Estas soluciones resuelven la sobreabundancia de información articulando dos enfoques esenciales: el Filtrado Basado en Contenido (CBF) y el Filtrado Colaborativo (CF). Sin embargo, la literatura reciente converge cada vez más hacia arquitecturas híbridas que combinan ambos paradigmas para compensar sus debilidades estructurales individuales.

Aplicación de TF-IDF y Similitud del Coseno en el Procesamiento de Metadatos Cinematográficos

En el paradigma del filtrado basado en contenido, el objetivo principal es construir perfiles vectoriales robustos para los ítems a partir de su información cualitativa. Proyectos académicos y sistemas comerciales recurren a la vectorización de texto para transformar variables categóricas tales como sinopsis, géneros, directores y miembros del elenco en variables numéricas continuas. El hito industrial más representativo de esta metodología se observa en el *Music Genome Project* de Pandora, plataforma pionera que demostró que diseccionar meticulosamente los atributos intrínsecos de un ítem mediante el etiquetado manual de hasta 450 descriptores musicales permite sugerir contenido altamente relevante y resolver el problema del ítem nuevo sin depender del historial de otros usuarios [1].

En este contexto, la investigación de Snigdha et al. [2] demuestra la viabilidad de utilizar el modelo de Frecuencia de Término–Frecuencia Inversa de Documento (TF-IDF) para este propósito. Al aplicarse a un sistema de recomendación de películas, TF-IDF actúa reduciendo el ruido de palabras comunes y penalizando o priorizando términos según su especificidad en el catálogo. Una vez contruidos los vectores característicos de las películas, el cálculo de la Similitud del Coseno se establece como la métrica geométrica estándar para medir el ángulo entre dichos vectores en un espacio multidimensional, superando en precisión y estabilidad a métricas de distancia tradicionales como la euclidiana [2]. Trabajos posteriores como el de Ni et al. [3] refuerzan esta combinación al incorporar TF-IDF junto con características explícitas del usuario dentro de un mismo pipeline de filtrado colaborativo, evidenciando que la técnica no solo resuelve el arranque en frío (*cold start*) de ítems, sino que también es extensible a esquemas híbridos.

Factorización de Matrices y Descenso de Gradiente Estocástico (SGD) en Grandes Catálogos

Cuando el sistema requiere capturar patrones complejos de comportamiento que trascienden los atributos textuales, el Filtrado Colaborativo mediante Factorización de Matrices (MF) se consolida como el estándar de la industria. El hito histórico más significativo de este enfoque se originó en el *Netflix Prize*, una competencia abierta sobre un conjunto de más de 100 millones de calificaciones anónimas [4], donde algoritmos basados en la descomposición de matrices superaron las técnicas tradicionales de correlación de vecindades, demostrando que las preferencias humanas pueden reducirse a un conjunto óptimo de características latentes.

Matemáticamente, este proceso implica descomponer una matriz dispersa de interacciones en dos matrices de menor rango que representan los factores latentes de los usuarios y de las películas. Gemulla et al. [5] abordan el desafío computacional de este modelo en entornos industriales de alta demanda, donde los catálogos masivos generan matrices con niveles críticos de dispersión (*sparsity*). Su investigación demuestra que la minimización de la función de pérdida cuadrática se optimiza eficientemente mediante el Descenso de Gradiente Estocástico (SGD), introduciendo el marco *Distributed Stochastic Gradient Descent* (DSGD) [5].

Complementando esta perspectiva de alto rendimiento, Zhuang et al. [6] exponen la implementación práctica de estos modelos en sistemas de memoria compartida, trabajo fundacional para *LibMF*. El SGD itera recursivamente sobre las interacciones existentes, ajustando los factores latentes mediante una tasa de aprendizaje (α) y un término de regularización L_2 para evitar el sobreajuste en usuarios con pocas calificaciones [6]. La calibración de estos hiperparámetros no es trivial: Fallah et al. [7] demuestran mediante *auto-tuning* automatizado que la elección de k , α y el coeficiente de regularización λ tiene un impacto crítico y no lineal sobre la convergencia del modelo, justificando metodológicamente la necesidad de un proceso de *Grid Search* como el aplicado en este proyecto.




Figura 1: Estructura del conjunto de datos del Premio Netflix.

Filtrado Colaborativo Basado en Memoria y Análisis de Vecindad (KNN)

Si bien los modelos de factores latentes dominan por su escalabilidad, el filtrado colaborativo basado en memoria, específicamente el algoritmo de *K-Nearest Neighbors* (KNN), se mantiene como un estándar robusto en la literatura debido a su alta interpretabilidad y precisión en entornos con alta correlación histórica. El caso de éxito comercial absoluto de este modelo es el motor de recomendaciones “Item-to-Item”, documentado formalmente por Linden, Smith y York [8] e implementado por Amazon a principios de la década de 2000. Mientras los primeros sistemas colapsaban al intentar comparar a millones de usuarios entre sí, este enfoque demostró que calcular la vecindad directamente entre los ítems transformaba por completo la escalabilidad del comercio electrónico.

Respaldao este hito industrial, la investigación fundacional de Sarwar et al. [9] demostró formalmente que calcular la similitud entre los vectores de calificación de los ítems (películas) en lugar de calcularla entre usuarios mejora drásticamente el rendimiento computacional y la calidad del ranking. En arquitecturas modernas, el KNN exige un tratamiento riguroso de la dispersión de datos, recurriendo frecuentemente a técnicas de imputación (como la imputación cero) para permitir el cálculo de distancias geométricas mediante la Similitud del Coseno [9].

Métricas de Evaluación y Comparación de Modelos

En este análisis se establece que ningún algoritmo es universalmente superior; su eficacia depende de la arquitectura del catálogo y la densidad de interacciones. Por ello, la literatura exige una evaluación cruzada utilizando conjuntos de datos particionados (*Train/Test Split*). Para medir la exactitud predictiva de calificaciones continuas, métricas como la Raíz del Error

Cuadrático Medio (RMSE) y el Error Absoluto Medio (MAE) son el estándar de la industria, ya que penalizan matemáticamente las desviaciones severas frente a la media real. Simultáneamente, para evaluar la utilidad de la interfaz de cara al usuario, los sistemas se auditan bajo métricas de Recuperación de Información, destacando *Precision@K* y *Recall@K*, las cuales validan qué proporción de los ítems sugeridos en el *Top-K* cruzan efectivamente el umbral de interés del consumidor.

Sistemas Híbridos de Recomendación

El reconocimiento de que CBF y CF resuelven problemas complementarios y no equivalentes dio origen a una línea de investigación dedicada explícitamente a su combinación. Burke [10], en el trabajo fundacional sobre sistemas híbridos, clasifica formalmente las estrategias de combinación (ponderada, conmutada, mixta, en cascada, *feature combination*, entre otras) y demuestra empíricamente que los enfoques híbridos superan consistentemente a sus componentes individuales en precisión, al mismo tiempo que mitigan el arranque en frío y la dispersión de calificaciones las dos limitaciones que el filtrado colaborativo puro no puede resolver por sí solo.

Esta línea ha sido validada específicamente sobre el dominio cinematográfico: Widayanti et al. [11] combinan filtrado colaborativo y basado en contenido para mejorar la diversidad y precisión de las recomendaciones frente a los modelos puros, mientras que el sistema *HybridFlicks* de Sharma et al. [12] integra explícitamente Factorización de Matrices con TF-IDF y Similitud del Coseno la misma combinación algorítmica empleada en MOVIE_ML reportando mejoras medibles en *recall* y *F1-score* frente a la implementación aislada de cada técnica. Estos antecedentes confirman que la arquitectura híbrida no es solo una conveniencia de ingeniería, sino una estrategia respaldada empíricamente por la literatura reciente del dominio.

Consideraciones sobre Aprendizaje Profundo y Costo Computacional

La literatura más reciente explora también arquitecturas de *Deep Learning* (autoencoders, redes neuronales convolucionales y *Graph Neural Networks*) para capturar patrones no lineales en los datos de interacción. No obstante, estos modelos presentan limitaciones documentadas de costo computacional y tiempo de entrenamiento que pueden ser desproporcionadas frente a la ganancia de precisión obtenida, particularmente en catálogos de tamaño moderado como el utilizado en este proyecto. Esta observación se respalda empíricamente en mediciones de consumo energético: Purificato y Silvestri [13] reportan, citando mediciones de hardware de Vente et al., que los modelos de aprendizaje profundo consumen en promedio hasta 60 veces más energía que modelos clásicos de vecindad (*UserKNN*), mientras logran únicamente entre el 95 % y el 98 %

de su precisión relativa un claro caso de rendimientos marginales decrecientes. Esta evidencia respalda la decisión metodológica de priorizar técnicas clásicas de álgebra lineal y optimización numérica (TF-IDF, MF-SGD, KNN) sobre arquitecturas de *Deep Learning* para el alcance de MOVIE_ML.

Síntesis y Brecha Identificada

La revisión de la literatura evidencia que CBF resuelve el arranque en frío pero ignora el comportamiento colectivo; la Factorización de Matrices captura patrones latentes complejos pero requiere de un volumen mínimo de interacciones reales para converger de forma estable; y el KNN ofrece alta interpretabilidad pero degrada críticamente su desempeño en entornos de alta dispersión. Ningún enfoque aislado cubre simultáneamente estas tres exigencias. A esto se suma una limitación particular del dataset TMDb: la ausencia de interacciones reales de usuario, que invalida de origen cualquier modelo puramente colaborativo. La literatura sobre sistemas híbridos [10, 11, 12] confirma que la combinación estructurada de estos enfoques es la estrategia más efectiva para cerrar esta brecha, lo cual constituye la motivación directa del diseño metodológico de MOVIE_ML: un ecosistema que articula CBF, MF-SGD y KNN sobre un entorno controlado de usuarios sintéticos, evaluado bajo estándares industriales (RMSE, MAE, *Precision@K*, *Recall@K*).

METODOLOGÍA

1. Descripción de los Datos y Preprocesamiento

El proyecto se fundamenta en el dataset TMDb 5000 Movie Dataset, el cual proporciona metadatos detallados y créditos técnicos. La metodología de tratamiento de datos se diseñó para garantizar la integridad estructural y la viabilidad matemática de los algoritmos posteriores.

Exploración y Limpieza: Se evaluó la distribución de variables cuantitativas (presupuesto, ingresos, duración) y cualitativas. Se aplicó la remoción estricta de registros con valores nulos críticos y se implementó un escalamiento logarítmico sobre las variables financieras para mitigar el impacto estadístico de valores atípicos (outliers).

Vectorización de Metadatos (Tag Soup): Los identificadores cualitativos complejos (géneros, elenco principal, director y palabras clave) se normalizaron extrayendo los espacios en blanco (ej. “James Cameron” a “JamesCameron”) para asegurar que el sistema trate cada entidad como un token unívoco. Estos se concatenaron en un corpus de texto denso por película, preparando el terreno para el procesamiento de lenguaje natural.

Simulación de Interacciones (Usuarios Sintéticos): Ante la carencia de valoraciones de usuarios reales en el dataset original una limitante común en arquitecturas de cold start se construyó un entorno controlado. Se generaron perfiles de usuarios sintéticos asignando calificaciones basadas en la tendencia de votación real de cada película (distribución normal estadística), introduciendo un factor de varianza probabilística. Esto permitió obtener una matriz de interacciones válida para entrenar los modelos colaborativos.

Segmentación de Experimentación: La matriz resultante se dividió bajo el esquema estocástico del 80 % para entrenamiento (Train) y 20 % para validación (Test), garantizando la integridad de las métricas de evaluación.

2. Modelo 1: Filtrado Basado en Contenido (Content-Based)

Hipótesis del algoritmo: Películas que comparten una estructura semántica similar en sus atributos intrínsecos (géneros, equipo técnico y sinopsis) satisfacen la misma necesidad de consumo en el usuario, permitiendo calcular su proximidad geométrica independientemente de la popularidad.

Para probar esta hipótesis, el “Tag Soup” de cada película se transformó en un espacio vectorial multidimensional.

Vectorización TF-IDF: Se aplicó la métrica de Frecuencia de Término – Frecuencia Inversa de Documento para ponderar la importancia de cada atributo. Los términos descriptivos únicos

reciben mayor peso, mientras que los términos genéricos son penalizados.

$$TF-IDF(t, d) = TF(t, d) \times \log \left(\frac{N}{df(t)} \right)$$

Normalización y Similitud: Para garantizar que la longitud de las descripciones no sesgue el algoritmo, se aplicó una normalización L2, proyectando los vectores en un hiperplano unitario. La proximidad temática se calculó mediante la Similitud del Coseno, aislando el ángulo entre vectores:

$$\cos(\theta) = \frac{A \cdot B}{\|A\| \cdot \|B\|}$$

Parámetros: El modelo ordenó el espacio vectorial devolviendo un ranking absoluto (Sorting) de los ítems con un $\cos(\theta)$ más cercano a 1.

3. Modelo 2: Factorización de Matrices con SGD

Hipótesis del algoritmo: Las interacciones entre usuarios y películas pueden explicarse matemáticamente proyectando ambos en un espacio común de dimensiones inferiores (factores latentes), donde el producto interno de sus vectores modela la preferencia subyacente.

Este modelo descompone la matriz original de interacciones R en una matriz de perfiles de usuario P y una matriz de atributos de película Q , tal que $R \approx P \cdot Q^T$.

Predicción: La calificación estimada $\hat{r}_{ui}$ se define como:

$$\hat{r}_{ui} = p_u \cdot q_i^T$$

Función de Pérdida y Regularización: El objetivo fue minimizar el Error Cuadrático Medio introduciendo la Regularización L2 (λ) (Penalización de Ridge) para controlar la magnitud de las matrices y evitar el sobreajuste (overfitting).

$$\mathcal{L} = \sum_{(u,i) \in \Omega} (r_{ui} - \hat{r}_{ui})^2 + \lambda(\|p_u\|^2 + \|q_i\|^2)$$

Optimización (SGD): La minimización se ejecutó mediante Descenso de Gradiente Estocástico. Calculando las derivadas parciales respecto a p_u y q_i , se actualizaron los pesos iterativamente escalados por la tasa de aprendizaje α :

$$p_u \leftarrow p_u + \alpha(e_{ui} \cdot q_i - \lambda \cdot p_u)$$

$$q_i \leftarrow q_i + \alpha(e_{ui} \cdot p_u - \lambda \cdot q_i)$$

Definición de Parámetros de Experimentación: Se sometió el modelo a calibración (Grid Search) estableciendo el número de dimensiones latentes (k), la tasa de aprendizaje (α para controlar la estabilidad de la convergencia) y las iteraciones máximas (epochs).

4. Modelo 3: K-Nearest Neighbors (KNN Colaborativo)

Hipótesis del algoritmo: Ítems que exhiben un comportamiento de calificación históricamente correlacionado dentro de una cohorte de usuarios mantendrán esa afinidad predictiva para valoraciones futuras (filtrado basado en memoria).

Tratamiento de Dispersión: Dado que KNN requiere cruzar la matriz completa de interacciones, se aplicó imputación cero a las celdas vacías de la matriz de entrenamiento.

Cálculo de Distancias: Se empleó la métrica de Similitud Coseno directamente sobre los vectores empíricos de las películas (ítems) en relación con las valoraciones de los usuarios.

Parámetros: Se definió el parámetro K (número de vecinos) para establecer el radio de búsqueda. Dada una película, el sistema calcula matemáticamente la menor distancia frente al resto del catálogo y predice la preferencia asumiendo que los patrones de la vecindad estadística son extrapolables.

5. Evaluación y Veredicto Computacional

El desempeño de las hipótesis algorítmicas se verificó cruzando las predicciones contra el Conjunto de Prueba (Test Set), aislado estrictamente durante la fase de optimización.

Exactitud Predictiva: Se evaluó la magnitud del error de las predicciones continuas. Se priorizó la Raíz del Error Cuadrático Medio (RMSE) debido a su sensibilidad paramétrica para penalizar desviaciones severas frente a la media real.

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (r_i - \hat{r}_i)^2}$$

Se complementó con el Error Absoluto Medio (MAE) para documentar el margen de error lineal.

Calidad de Ranking: Se aplicaron las métricas de Recuperación de Información Precision@K y Recall@K para validar la utilidad real del algoritmo frente a la experiencia del usuario final, midiendo específicamente qué proporción de las recomendaciones del Top-K cruzaban exitosamente el umbral de preferencia del usuario sintético.

6. Experimento de Robustez y Análisis de Sensibilidad

Para validar la estabilidad de las hipótesis algorítmicas frente a entornos de alta incertidumbre y perturbaciones en los datos, se diseñó un experimento de robustez consistente en 10 corridas estocásticas independientes bajo tres niveles de variabilidad o desorden en las calificaciones de los usuarios sintéticos. El nivel de ruido se parametrizó mediante la desviación estándar (σ) en la distribución de las notas: opiniones unánimes ($\sigma = 1,0$), opiniones realistas o moderadas ($\sigma = 2,0$), y opiniones altamente dispersas o extremas ($\sigma = 3,0$).

La metodología analítica para contrastar el comportamiento y la resiliencia de cada modelo ante estas condiciones de ruido se estructuró bajo los siguientes criterios:

Estabilidad en Filtrado Basado en Contenido: Se determinó que este enfoque es completamente inmune al ruido de las calificaciones (100 % independiente del comportamiento del usuario). Al fundamentarse estrictamente en la similitud geométrica del *Tag Soup* y la vectorización TF-IDF, las distancias inter-ítem permanecen inalteradas frente a la polarización extrema de opiniones o la escasez crítica de interacciones, resolviendo la vulnerabilidad por diseño estructural.

Robustez en Factorización de Matrices (MF + SGD): La proyección de la matriz de interacciones en un espacio de factores latentes reducidos ($k = 20$) funciona como un filtro matemático que captura las tendencias macroestructurales de preferencia y descarta el ruido aleatorio individual. Bajo perturbaciones severas ($\sigma = 3,0$), el algoritmo SGD demostró la mayor robustez empírica manteniendo errores acotados.

Adicionalmente, se incorporó un análisis de sensibilidad sobre la tasa de aprendizaje (α) evaluando la convergencia del RMSE en el conjunto de prueba durante 50 épocas. Se comprobó que valores conservadores ($\alpha = 0,005$ o $\alpha = 0,001$) garantizan una convergencia asintótica y estable, mientras que valores excesivos ($\alpha \geq 0,05$) provocan la divergencia drástica del gradiente numérico, resultando en indeterminaciones matemáticas (errores NaN).

Sensibilidad en KNN Colaborativo: Al ser un modelo basado en memoria que opera directamente sobre vectores de calificaciones crudas para calcular la Similitud del Coseno, su precisión es altamente dependiente de la estabilidad de los votos. Ante niveles altos de ruido ($\sigma = 3,0$), su capacidad de generalización decae debido a que la distorsión en los vectores de ítems altera el cálculo de las vecindades estadísticas (K), propagando el error en las ponderaciones.

Evaluación por Rangos de Calificación y Actividad (Sparsity): El experimento segmentó el rendimiento del Error Absoluto Medio (MAE) bajo dos dimensiones operativas críticas para mapear las debilidades de los modelos:

- *Rangos de Calificación:* Las valoraciones reales se clasificaron en bajas ($[1, 4)$), medias ($[4, 7)$)

y altas ([7, 10]). Se analizó la capacidad de los modelos para mantener un rendimiento homogéneo en los extremos, demostrando que la Factorización de Matrices distribuye el error de forma balanceada, a diferencia de KNN, cuyo sesgo predictivo se concentra en el promedio vecinal.

- *Densidad de Actividad (Sparsity / Cold-Start)*: Se contrastó el impacto del sistema en perfiles con bajo historial de interacción frente a usuarios altamente activos. El modelo KNN exhibe una degradación crítica en entornos de alta dispersión debido a la ausencia de vecinos estadísticos válidos, mientras que la Factorización de Matrices mitiga el fenómeno generalizando a través de los sesgos globales y vectores latentes compartidos.

Experimentación y Resultados

En esta sección se detalla la implementación técnica y los hallazgos cuantitativos del modelo K -Nearest Neighbors (KNN) desarrollado de forma manual.

Configuración del Experimento

Se utilizaron las matrices procesadas `ratings_train.npy` y `ratings_test.npy`. La experimentación se centró en la optimización del hiperparámetro K (número de vecinos), evaluando valores de $K \in \{5, 10, 20, 50\}$. El cálculo de similitud se realizó mediante la Similitud de Coseno, implementada a través de operaciones vectorizadas en NumPy para maximizar la eficiencia numérica.

Resultados Cuantitativos

Los resultados obtenidos tras la ejecución del modelo KNN con los datos procesados se presentan en la Tabla 1.

Cuadro 1: Evaluación del modelo KNN para diferentes valores de K .

Valor de K	RMSE (Error Cuadrático Medio)	MAE (Error Absoluto Medio)
5	1.3787	1.0958
10	1.3256	1.0552
20 (Óptimo)	1.2995	1.0346
50	1.2957	1.0330

Discusión

El análisis de los resultados permite extraer las siguientes observaciones desde la perspectiva de Métodos Numéricos y Optimización:

- **Estabilidad de la similitud:** La implementación manual de la similitud de coseno demostró ser robusta. Para evitar errores de división por cero en películas con pocos ratings, se reemplazaron las normas nulas por 1 (`norms[norms == 0] = 1`), garantizando que el algoritmo no colapse ante datos dispersos (*sparsity*).
- **Comportamiento del Hiperparámetro K :** Se observó que un K muy bajo genera “ruido” en la recomendación (*overfitting* a vecinos atípicos), mientras que un K muy alto suaviza demasiado las predicciones. El valor de $K = 20$ resultó ser el punto de equilibrio práctico donde el error se estabiliza de forma óptima.

- **Eficiencia Computacional:** Al evitar frameworks tradicionales como *scikit-learn* y utilizar directamente el producto punto matricial ($A \cdot B^T$), se logró reducir el tiempo de cálculo de la matriz de similitud de minutos a segundos, aprovechando la optimización intrínseca de los arreglos de NumPy.

Conclusiones y Trabajos Futuros

- Se logró diseñar un sistema de recomendación funcional utilizando métodos directos de álgebra lineal, cumpliendo con la restricción de no emplear frameworks de modelado automáticos.
- El uso de formatos binarios (`.npy`) fue crítico para la persistencia y velocidad de carga de los datos, demostrando que la estructura de los datos es tan importante como el algoritmo mismo.
- La validación mediante RMSE manual permitió confirmar que el modelo tiene una precisión aceptable para una base de datos de 5000 películas.

Trabajos Futuros

- **Paralelización:** Implementar el cálculo de similitudes usando programación paralela o GPU (CUDA) para escalar el sistema a millones de usuarios.
- **Hibridación:** Integrar técnicas de Factorización de Matrices para resolver el problema de datos faltantes que el algoritmo KNN por sí solo no puede cubrir de manera eficiente.

Referencias

- [1] Schedl, M., Knees, P., McFee, B., Bogdanov, D., & Kaminskas, M. (2018). *Current Challenges and Visions in Music Recommender Systems Research*. arXiv preprint arXiv:1710.03208.
- [2] Snigdha et al. (2025). Movie Recommendation Using TF-IDF Vectorization and Cosine Similarity. *International Research Journal of Engineering and Technology (IRJET)*, 12(6).
- [3] Ni, J., Cai, Y., Tang, G., & Xie, Y. (2021). Collaborative filtering recommendation algorithm based on TF-IDF and user characteristics. *Applied Sciences*, 11(20), 9554.
- [4] Bennett, J., & Lanning, S. (2007). The Netflix Prize. *Proceedings of KDD Cup and Workshop 2007*, pp. 3–6, ACM, San José.
- [5] Gemulla, R., Nijkamp, E., Haas, P. J., & Sismanis, Y. (2011). Large-Scale Matrix Factorization with Distributed Stochastic Gradient Descent. *Proceedings of the 17th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, ACM, Nueva York.
- [6] Zhuang, W.-S., Chin, W.-S., Juan, Y.-C., & Lin, C.-J. (2013). *A Fast Parallel SGD for Matrix Factorization in Shared Memory Systems*. Technical Report, Department of Computer Science, National Taiwan University, Taipei.
- [7] Fallah et al. (2022). Auto-tuning HyperParameters of SGD Matrix Factorization-Based Recommender Systems. *IEEE Xplore*, IEEE.
- [8] Linden, G., Smith, B., & York, J. (2003). Amazon.com Recommendations: Item-to-Item Collaborative Filtering. *IEEE Internet Computing*, 7(1), 76–80.
- [9] [9] Sarwar, B., Karypis, G., Konstan, J., & Riedl, J. (2001). Item-based collaborative filtering recommendation algorithms. *Proceedings of the 10th International Conference on World Wide Web*, ACM, Hong Kong, pp. 285–295.
- [10] [10] Burke, R. (2002). Hybrid Recommender Systems: Survey and Experiments. *User Modeling and User-Adapted Interaction*, 12(4), 331–370.
- [11] Widayanti, R., Chakim, M. H. R., Lukita, C., Rahardja, U., & Lutfiani, N. (2023). Improving recommender systems using hybrid techniques of collaborative filtering and content-based filtering. *Journal of Applied Data Science*, 4(3).
- [12] Sharma et al. (2025). HybridFlicks: Integrating Collaborative Filtering and Content-Based Methods for Enhanced Movie Recommendations. *Multimedia Tools and Applications*, Springer.

- [13] Purificato, A., & Silvestri, F. (2025). *The Environmental Impact of Ensemble Techniques in Recommender Systems*. arXiv preprint arXiv:2511.11649.