

UNIVERSIDAD PERUANA CAYETANO HEREDIA
FACULTAD DE CIENCIAS E INGENIERÍA
“ALBERTO CAZORLA TALLER”



TEMA:

Sistema de Recomendación de Películas

CURSO:

Métodos Numéricos y Optimización para Machine Learning

ALUMNOS:

ANDRES STEVEN RODAS JANAMPA
MARCELO JOEL RODRIGUEZ CABRERA
PATRICIA DEL PILAR REBATTI JERI

PROFESORES:

JOSUE ANGEL MAURICIO SALAZAR
JEREMY KARSEN HOLGUIN MORI

Lima - Perú

2025

Abstract

El fenómeno de la sobreabundancia de información en las plataformas de streaming modernas genera fatiga de decisión en los usuarios, requiriendo sistemas eficientes de filtrado de contenido. El presente proyecto, denominado MOVIE_ML, desarrolla un ecosistema híbrido de recomendación basado en el dataset TMDb para mitigar este problema mediante técnicas de álgebra lineal y optimización numérica. La metodología se estructura en un flujo de procesamiento de datos riguroso que aborda el problema de la dispersión matricial (sparsity) mediante la normalización heterogénea de metadatos. Se implementa un motor de filtrado basado en contenido, el cual consolida atributos cualitativos en un espacio semántico (Tag Soup) y emplea vectorización TF-IDF con normalización L2 para calcular la Similitud del Coseno, resolviendo eficazmente el problema de arranque en frío (cold start). Adicionalmente, para capturar patrones de comportamiento latentes, se diseña un entorno de simulación poblacional con usuarios sintéticos, sobre el cual se ejecuta una arquitectura de optimización mediante Factorización de Matrices y Descenso de Gradiente Estocástico (SGD). La evaluación sistémica del modelo se alinea con estándares industriales (Precisión@K y RMSE), demostrando cómo la intersección entre ingeniería de características y métodos probabilísticos permite construir una herramienta altamente escalable que transforma el gusto cinematográfico en una variable estrictamente cuantificable y geométricamente optimizable.

INTRODUCCIÓN

En la era de la economía digital, las plataformas de streaming enfrentan el fenómeno de la sobreabundancia de información, donde la inmensidad de los catálogos genera en el usuario una fatiga de decisión que degrada la experiencia de consumo. Ante esta necesidad de filtrar contenido de manera eficiente, nace el proyecto MOVIE_ML: un proyecto de recomendación construido sobre el dataset de TMDB que transforma la búsqueda de contenido en una experiencia de descubrimiento geoméricamente optimizada.

El núcleo del sistema reside en la aplicación de álgebra lineal y métodos numéricos de alto rendimiento. Mediante la vectorización de metadatos cualitativos (reparto, géneros y dirección) en espacios multidimensionales, el sistema emplea el cálculo de la similitud del coseno para determinar la proximidad geométrica entre contenidos, tratando el gusto cinematográfico como una variable cuantificable.

No obstante, el rigor del proyecto trasciende la comparación de atributos al implementar una arquitectura de Factorización de Matrices optimizada mediante el Descenso de Gradiente Estocástico (SGD). Debido a la ausencia de interacciones reales en el conjunto de datos original, se desarrolló un entorno controlado de usuarios sintéticos y calificaciones simuladas bajo distribuciones normales, permitiendo al algoritmo minimizar iterativamente la función de pérdida y capturar factores latentes de preferencia. A través de este enfoque híbrido, el proyecto demuestra cómo la intersección entre la subjetividad humana y la precisión algorítmica permite construir una herramienta que se ajusta matemáticamente a la identidad de cada usuario.

ESTADO DEL ARTE

Ingesta y Consolidación

El Problema de la Dispersión en cualquier sistema de recomendación, el número de valoraciones disponibles es significativamente menor al total de valoraciones posibles. Esta brecha genera una matriz usuario-ítem escasa que degrada la precisión predictiva de los algoritmos.

El proyecto MovieLens, desarrollado por GroupLens Research, fue el primero en demostrar este fenómeno a escala real. Al consolidar millones de valoraciones de usuarios reales, documentaron que la dispersión (sparsity) supera el 95 % de entradas sin valorar y constituye uno de los principales obstáculos para los sistemas colaborativos cuando las matrices son muy escasas, los algoritmos de vecindad más cercana fallan al no encontrar suficientes usuarios similares [1]. A medida que crece el catálogo de ítems, la dimensión de la matriz y su dispersión aumentan exponencialmente, afectando directamente la calidad de recomendación [1].

Para mitigar este problema, el presente proyecto adopta una estrategia de normalización de fuentes heterogéneas, integración matricial con integridad de metadatos y transformación vectorial previa al modelado, siguiendo los principios de preprocesamiento documentados por GroupLens [1].

Características TF-IDF y Espacio Vectorial

El Proyecto Genoma Musical de Pandora es uno de los casos más representativos de ingeniería de características aplicada a recomendación basada en contenido. Sus ingenieros clasifican cada canción mediante cientos de “genes musicales” atributos como ritmo, tonalidad, instrumentación y letra que luego son vectorizados para calcular similitudes entre ítems [2]. Este enfoque es estructuralmente análogo al “Tag Soup” implementado en este proyecto: la concatenación de género, director, actores y sinopsis de cada película para construir un espacio vectorial de características.

Se establece que el pesado TF-IDF es el método estándar para transformar atributos cualitativos en vectores numéricos. El término TF mide la frecuencia local de un término en el ítem; el IDF penaliza términos muy comunes que aportan poco poder discriminativo:

$$TF-IDF_{t,d} = TF_{t,d} \log \frac{N}{df_t}$$

La normalización L2 escala cada vector al hiperplano unitario, haciendo que la similitud del coseno sea invariante a la longitud del documento:

$$\vec{v} = \frac{\vec{v}}{\|\vec{v}\|_2}$$

Una aportación clave de este paradigma documentada también por Pandora es resolver el problema de cold start al depender de atributos intrínsecos del ítem y no de su historial de valoraciones, el sistema puede generar recomendaciones desde el primer contacto con el usuario [2].

Motor de Recomendación: Similitud del Coseno

El sistema de recomendación de Amazon demostró que es computacionalmente más eficiente calcular similitudes entre ítems que entre usuarios, especialmente en catálogos de millones de productos. En lugar de encontrar usuarios similares al activo, Amazon pre calcula para cada producto cuáles son sus ítems más parecidos, reduciendo la complejidad en tiempo de respuesta de $O(MN)$ a $O(N)$ [3].

La métrica central de este enfoque es la Similitud del Coseno, consolidada como el estándar de facto para sistemas de recomendación basados en contenido e ítem-ítem. A diferencia de la distancia euclidiana, mide el ángulo entre dos vectores en lugar de su separación absoluta, siendo invariante a la magnitud, con un rango $[-1, 1]$ donde 1 indica máxima similitud:

$$\cos(\theta) = \frac{A \cdot B}{\|A\| \|B\|}$$

Esta propiedad es crucial en catálogos extensos: dos películas de géneros similares tendrán vectores TF-IDF apuntando en la misma dirección aunque sus magnitudes difieren por ejemplo, una sinopsis corta frente a una larga [3]. Las recomendaciones resultantes son coherentes con los atributos intrínsecos de los ítems, sin depender de patrones de comportamiento colectivo [3].

Factorización de Matrices: SGD y Factores Latentes

La Netflix Prize Competition es el hito fundacional del filtrado colaborativo moderno. El equipo ganador BellKor's Pragmatic Chaos, liderado por Yehuda Koren, demostró que los modelos de Factorización de Matrices superan a las técnicas clásicas de vecindad más cercana, permitiendo incorporar retroalimentación implícita, efectos temporales y niveles de confianza [4].

Koren, Bell & Volinsky proponen descomponer la matriz de interacciones usuario-ítem en dos matrices de menor dimensión: una de factores de usuario (P) y una de factores de ítem (Q) [4]. Cada dimensión latente captura una característica oculta del gusto como la preferencia por películas de acción o dramas de época sin que sea necesario definirla explícitamente [4]. La predicción de valoración se calcula como:

$$r_{ui} = b + b_u + b_i + p_u^T q_i$$

Donde b es la media global, b_u el sesgo del usuario y b_i el sesgo del ítem [4]. El algoritmo SGD actualiza los parámetros tras cada ejemplo de entrenamiento, estimando r_{ui} , calculando el error $e_{ui} = r_{ui} - \hat{r}_{ui}$ y ajustando P y Q en la dirección que reduce dicho error, controlado por la tasa de aprendizaje α y el término de regularización β [4].

En este proyecto se diseñó un entorno de usuarios sintéticos para ejecutar SGD, dado que el dataset original no contenía valoraciones históricas para entrenar el filtro colaborativo problema de escasez de datos documentado precisamente por el equipo de Netflix [4].

Evaluación Sistémica: Métricas de Error y Ranking

Gunawardana & Shani establecen el marco de referencia para la evaluación de sistemas de recomendación, distinguiendo entre métricas de exactitud predictiva y métricas de ranking [5]. Las métricas RMSE y MAE miden la distancia entre la valoración predicha y la real: el RMSE penaliza más los errores grandes y constituyó el estándar oficial de la Netflix Prize Competition para comparar modelos [4][5].

La métrica Precision@K representa la fracción de ítems relevantes entre los K primeros recomendados, siendo la más directamente interpretable: de los 10 primeros títulos sugeridos, ¿cuántos son realmente de su gusto? [5]. Complementariamente, el Recall@K

mide qué proporción de los ítems relevantes totales aparecen en las K recomendaciones; el balance Precision–Recall define la utilidad global del sistema [5].

Estos criterios son consistentes con los marcos de evaluación utilizados por MovieLens (offline evaluation sobre particiones de train/test) y por Amazon (evaluación A/B en producción), lo que valida su aplicabilidad tanto en contextos académicos como industriales [1][3][5].

METODOLOGÍA

1. Descripción de los Datos y Preprocesamiento

El proyecto se fundamenta en el dataset TMDb 5000 Movie Dataset, el cual proporciona metadatos detallados y créditos técnicos. La metodología de tratamiento de datos se diseñó para garantizar la integridad estructural y la viabilidad matemática de los algoritmos posteriores.

Exploración y Limpieza: Se evaluó la distribución de variables cuantitativas (presupuesto, ingresos, duración) y cualitativas. Se aplicó la remoción estricta de registros con valores nulos críticos y se implementó un escalamiento logarítmico sobre las variables financieras para mitigar el impacto estadístico de valores atípicos (outliers).

Vectorización de Metadatos (Tag Soup): Los identificadores cualitativos complejos (géneros, elenco principal, director y palabras clave) se normalizaron extrayendo los espacios en blanco (ej. “James Cameron” a “JamesCameron”) para asegurar que el sistema trate cada entidad como un token unívoco. Estos se concatenaron en un corpus de texto denso por película, preparando el terreno para el procesamiento de lenguaje natural.

Simulación de Interacciones (Usuarios Sintéticos): Ante la carencia de valoraciones de usuarios reales en el dataset original una limitante común en arquitecturas de cold start se construyó un entorno controlado. Se generaron perfiles de usuarios sintéticos asignando calificaciones basadas en la tendencia de votación real de cada película (distribución normal estadística), introduciendo un factor de varianza probabilística. Esto permitió obtener una matriz de interacciones válida para entrenar los modelos colaborativos.

Segmentación de Experimentación: La matriz resultante se dividió bajo el esquema estocástico del 80 % para entrenamiento (Train) y 20 % para validación (Test), garantizando la integridad de las métricas de evaluación.

2. Modelo 1: Filtrado Basado en Contenido (Content-Based)

Hipótesis del algoritmo: Películas que comparten una estructura semántica similar en sus atributos intrínsecos (géneros, equipo técnico y sinopsis) satisfacen la misma necesidad de consumo en el usuario, permitiendo calcular su proximidad geométrica independientemente de la popularidad.

Para probar esta hipótesis, el “Tag Soup” de cada película se transformó en un espacio vectorial multidimensional.

Vectorización TF-IDF: Se aplicó la métrica de Frecuencia de Término – Frecuencia Inversa de Documento para ponderar la importancia de cada atributo. Los términos descriptivos únicos reciben mayor peso, mientras que los términos genéricos son penalizados.

$$TF-IDF(t, d) = TF(t, d) \times \log \left(\frac{N}{df(t)} \right)$$

Normalización y Similitud: Para garantizar que la longitud de las descripciones no sesgue el algoritmo, se aplicó una normalización L2, proyectando los vectores en un hiperplano unitario. La proximidad temática se calculó mediante la Similitud del Coseno, aislando el ángulo entre vectores:

$$\cos(\theta) = \frac{A \cdot B}{\|A\| \cdot \|B\|}$$

Parámetros: El modelo ordenó el espacio vectorial devolviendo un ranking absoluto (Sorting) de los ítems con un $\cos(\theta)$ más cercano a 1.

3. Modelo 2: Factorización de Matrices con SGD

Hipótesis del algoritmo: Las interacciones entre usuarios y películas pueden explicarse matemáticamente proyectando ambos en un espacio común de dimensiones inferiores (factores latentes), donde el producto interno de sus vectores modela la preferencia subyacente.

Este modelo descompone la matriz original de interacciones R en una matriz de perfiles de usuario P y una matriz de atributos de película Q , tal que $R \approx P \cdot Q^T$.

Predicción: La calificación estimada $\hat{r}_{ui}$ se define como:

$$\hat{r}_{ui} = p_u \cdot q_i^T$$

Función de Pérdida y Regularización: El objetivo fue minimizar el Error Cuadrático Medio introduciendo la Regularización L2 (λ) (Penalización de Ridge) para controlar la magnitud de las matrices y evitar el sobreajuste (overfitting).

$$\mathcal{L} = \sum_{(u,i) \in \Omega} (r_{ui} - \hat{r}_{ui})^2 + \lambda(\|p_u\|^2 + \|q_i\|^2)$$

Optimización (SGD): La minimización se ejecutó mediante Descenso de Gradiente Estocástico. Calculando las derivadas parciales respecto a p_u y q_i , se actualizaron los pesos iterativamente escalados por la tasa de aprendizaje α :

$$p_u \leftarrow p_u + \alpha(e_{ui} \cdot q_i - \lambda \cdot p_u)$$

$$q_i \leftarrow q_i + \alpha(e_{ui} \cdot p_u - \lambda \cdot q_i)$$

Definición de Parámetros de Experimentación: Se sometió el modelo a calibración (Grid Search) estableciendo el número de dimensiones latentes (k), la tasa de aprendizaje (α para controlar la estabilidad de la convergencia) y las iteraciones máximas (epochs).

4. Modelo 3: K-Nearest Neighbors (KNN Colaborativo)

Hipótesis del algoritmo: Ítems que exhiben un comportamiento de calificación históricamente correlacionado dentro de una cohorte de usuarios mantendrán esa afinidad predictiva para valoraciones futuras (filtrado basado en memoria).

Tratamiento de Dispersión: Dado que KNN requiere cruzar la matriz completa de interacciones, se aplicó imputación cero a las celdas vacías de la matriz de entrenamiento.

Cálculo de Distancias: Se empleó la métrica de Similitud Coseno directamente sobre los vectores empíricos de las películas (ítems) en relación con las valoraciones de los usuarios.

Parámetros: Se definió el parámetro K (número de vecinos) para establecer el radio de búsqueda. Dada una película, el sistema calcula matemáticamente la menor distancia frente al resto del catálogo y predice la preferencia asumiendo que los patrones de la vecindad estadística son extrapolables.

5. Evaluación y Veredicto Computacional

El desempeño de las hipótesis algorítmicas se verificó cruzando las predicciones contra el Conjunto de Prueba (Test Set), aislado estrictamente durante la fase de optimización.

Exactitud Predictiva: Se evaluó la magnitud del error de las predicciones continuas. Se priorizó la Raíz del Error Cuadrático Medio (RMSE) debido a su sensibilidad paramétrica para penalizar desviaciones severas frente a la media real.

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (r_i - \hat{r}_i)^2}$$

Se complementó con el Error Absoluto Medio (MAE) para documentar el margen de error lineal.

Calidad de Ranking: Se aplicaron las métricas de Recuperación de Información Precision@K y Recall@K para validar la utilidad real del algoritmo frente a la experiencia del usuario final, midiendo específicamente qué proporción de las recomendaciones del Top-K cruzaban exitosamente el umbral de preferencia del usuario sintético.

hyperref

FUENTES

1. GroupLens Research. (s.f.). *MovieLens Dataset*. Universidad de Minnesota. Disponible en:
<https://grouplens.org/datasets/movielens/>
2. Pandora Media. (s.f.). *Pandora Music Genome Project*. Disponible en:
<https://www.pandora.com/about/mgp>
3. Linden, G., Smith, B., & York, J. (2003). *Amazon.com Recommendations: Item-to-Item Collaborative Filtering*. IEEE Internet Computing, 7(1), 76–80. Disponible en:
<https://ieeexplore.ieee.org/document/1167344>
4. Koren, Y., Bell, R., & Volinsky, C. (2009). *Matrix Factorization Techniques for Recommender Systems*. IEEE Computer Society. Disponible en:
[https://datajobs.com/data-science-repo/Recommender-Systems-\[Netflix\].pdf](https://datajobs.com/data-science-repo/Recommender-Systems-[Netflix].pdf)
5. Gunawardana, A. & Shani, G. (2015). *Evaluating Recommender Systems*. En: Recommender Systems Handbook. Springer. Disponible en:
<https://link.springer.com/chapter/10.1007/978-1-4899-7637-68>